

GDPNow-Maroc

Correction de la fuite de données BVAR et optimisation de la fenêtre d'entraînement

Synthèse de l'intervention sur l'ensemble des 7 étapes

8 septembre 2026

Résumé

Ce document synthétise une correction méthodologique majeure trouvée en préparant l'optimisation de la fenêtre d'entraînement demandée : **le BVAR de l'Étape 1 n'a jamais respecté la période d'entraînement 2010–2021** utilisée par le reste du pipeline — il utilisait toute la plage disponible (1998–2026), contaminant silencieusement le test hors-échantillon de l'Étape 7. Corrigé, puis trois fenêtres de démarrage ont été testées (1998, 2005, 2010) pour trouver la meilleure combinaison.

1 La découverte

Découverte et correction

En examinant le script `03_bvar_estimation_et_choix_lambda.R` pour y ajouter une borne de démarrage ajustable, aucune restriction de date n'y a été trouvée — le BVAR utilisait `Y_complet`, construit à partir de **tout** le fichier source (1998–2026), avec sa propre validation interne à 80/20 (les 20% derniers trimestres pour choisir λ , mais jamais mis de côté entièrement).

Conséquence : les coefficients BVAR réutilisés dans les Étapes 5 à 7 avaient déjà « vu », au moins partiellement, la période 2021–2026 que l'Étape 7 prétendait tester en hors-échantillon — une fuite de données silencieuse, jamais détectée jusqu'ici.

2 La correction apportée

Une restriction stricte (`DATE_DEBUT_TRAIN`, `DATE_FIN_TRAIN` = 2021-01-01) a été ajoutée au script d'estimation, avant toute construction de `Y_complet` — alignée sur la même discipline suivie partout ailleurs depuis la Phase 2. Un script d'export manquant (`05_exporter_coefficients_bvar.R`) a également été créé, le fichier `coefficients_complets_BVAR.csv` n'ayant jusqu'ici jamais été reproduit par aucun script (un export manuel resté non tracé).

Découverte et correction

Un second bug d'encodage (déjà rencontré et corrigé ailleurs dans ce travail) est réapparu dans ce nouveau script d'export : `write.csv` (base R) corrompait les caractères accentués, là où `write_csv` (readr, UTF-8 explicite) ne le fait pas. Corrigé et vérifié fonctionnellement avant de poursuivre.

3 Impact de la correction sur le résultat déjà obtenu

	Avant correction (fuite)	Après correction
Corrélation en-échantillon (Étape 6)	0,671	0,622
Corrélation hors-échantillon (Étape 7)	0,541	0,292
RMSFE hors-échantillon	4,73	5,43

Découverte et correction

Le résultat honnête est moins bon que celui précédemment rapporté — attendu, puisque la version précédente bénéficiait (sans qu'on le sache) d'une information qu'un vrai modèle en production n'aurait jamais eue à ce stade. Ce n'est pas une régression du modèle, c'est la correction d'une évaluation qui était faussement optimiste.

4 Optimisation de la fenêtre de démarrage du BVAR

Intuition

Le BVAR n'utilise que les VA des 16 branches (disponibles depuis 1998) — contrairement aux bridge equations et aux AR, dont les indicateurs ne remontent souvent pas avant 2007–2010. Étendre son démarrage en arrière ne coûte donc rien en couverture d'indicateurs, et pourrait, en théorie, améliorer sa précision.

Démarrage BVAR	RMSFE validation interne	RMSFE final (Étape 7)	Corrélation finale
2010	0,1306	5,43	0,292
2005	0,1094	5,37	0,305
1998	0,0921	5,38	0,301

2005 obtient le meilleur résultat final, mais l'écart entre les trois candidats est minime (5,37 à 5,43 — de l'ordre du bruit statistique sur seulement $n = 20$ trimestres de test). Fait notable : la validation interne du BVAR s'améliore **nettement** avec plus d'historique (0,131 $\rightarrow$ 0,092, 1998 vs 2010) — un gain réel pour le BVAR pris isolément — **mais ce gain se propage à peine** jusqu'au résultat final agrégé.

Explication : la plupart des 16 δ (Étape 5) sont faibles (souvent $< 0,1$) — le résultat final dépend donc majoritairement des bridge equations et des AR, pas du BVAR. Améliorer le BVAR seul a un effet mécaniquement limité sur l'agrégat, quelle que soit sa propre qualité.

5 Décision retenue

Après réflexion, le BVAR est ramené à 2010–2021, strictement identique au reste du pipeline — pas 2005, malgré son gain marginal (5,37 contre 5,43). Le gain était trop faible pour justifier une asymétrie de fenêtre entre le BVAR et tous les indicateurs (Étapes 2–4), dont la sélection elle-même n'a jamais été retestée sur une fenêtre différente. Cohérence stricte préférée à un gain marginal non généralisé au reste du modèle.

Résultat final retenu : RMSFE hors-échantillon = **5,43** (croissance annualisée), corrélation = 0,292, sur les 20 mêmes trimestres jamais vus (2021T2–2026T1) — le vrai goulot d'étranglement de ce travail reste, sans ambiguïté, la richesse et la qualité des indicateurs propres à

chaque branche (Étapes 2–4), pas la fenêtre du BVAR.