

GDPNow-Maroc

Nowcasting sectoriel du PIB marocain :
construction du classeur synthétique, audit de fidélité et
modélisation branche par branche

Rapport de stage — Méthodologie et résultats

Komlan Matthania ADJOH

Avec les données sectorielles consolidées d'Alim ATCHADAM

Août 2026

1. Contexte et objectif

Ce rapport documente l'ensemble du travail réalisé durant le stage : la construction et la fiabilisation d'un classeur synthétique regroupant les séries statistiques nécessaires au nowcasting du Produit Intérieur Brut (PIB) marocain, puis la conception d'un modèle de nowcasting **sectoriel** — c'est-à-dire fondé sur la décomposition du PIB par branche d'activité (approche offre), et non par composante de la dépense (approche demande) comme le fait le modèle de référence international GDPNow de la Federal Reserve Bank d'Atlanta.

Le nowcasting désigne la prévision de la valeur d'un agrégat macroéconomique — ici le PIB — pour le trimestre en cours ou le trimestre le plus récent non encore publié, en s'appuyant sur des indicateurs infra-annuels (mensuels ou trimestriels) disponibles avant la publication officielle. Il s'oppose à la prévision de moyen terme : l'horizon est court (un trimestre), mais l'information disponible est incomplète et arrive de façon échelonnée dans le temps (« jagged edge », selon la terminologie de Giannone, Reichlin & Small, 2008).

Le rapport est structuré en deux grandes parties, correspondant aux deux volets du travail : **(I)** la construction, l'audit et la restauration du classeur de données synthétique à partir de la data lake fournie, et **(II)** la modélisation économétrique proprement dite, avec ses équations, son implémentation, sa validation et ses limites.

1.1 Ancrage dans la littérature

L'architecture du modèle et chacun de ses éléments méthodologiques s'appuient sur une littérature identifiée et citée explicitement, résumée dans le tableau suivant.

Élément méthodologique	Référence
Architecture générale (BVAR + bridge equations + agrégation)	Higgins, P. (2014). GDPNow: A Model for GDP “Nowcasting”. FRB Atlanta, Working Paper 2014-7.
Équations de passerelle (« bridge equations »)	Miller, P.J. & Chin, D.M. (1996). Using Monthly Data to Improve Quarterly Model Forecasts. FRB Minneapolis Quarterly Review.
Prior bayésien Minnesota (BVAR)	Litterman, R. (1986). Forecasting with Bayesian Vector Autoregressions. Journal of Business & Economic Statistics.
Méthode des observations fictives, grand BVAR	Bańbura, M., Giannone, D. & Reichlin, L. (2010). Large Bayesian VARs. Journal of Applied Econometrics, 25(1).
Gestion des données décalées (« jagged edge »)	Giannone, D., Reichlin, L. & Small, D. (2008). Nowcasting: The Real-Time Informational Content of Macroeconomic Data. Journal of Monetary Economics, 55.
Validation hors échantillon (RMSFE, pseudo temps réel)	Stock, J.H. & Watson, M.W. (2007). Why Has U.S. Inflation Become Harder to Forecast? Journal of Money, Credit and Banking.
Test de significativité de l'écart de précision	Diebold, F.X. & Mariano, R.S. (1995). Comparing Predictive Accuracy. Journal of Business and Economic Statistics.

Élément méthodologique	Référence
Agrégation Fisher / contributions à la croissance	Whelan, K. (2000). A Guide to the Use of Chain Aggregated NIPA Data. FED Board, FEDS Working Paper 2000-35.
Sélection des indicateurs par critère de corrélation	Fernández Cerezo, A. (2023). A Supply-Side GDP Nowcasting Model. Banco de España, Economic Bulletin.

Partie I — Construction et fiabilisation du classeur synthétique

Avant toute modélisation, le préalable indispensable était de disposer d'un classeur de données consolidées (« *Etude sectorielle Maroc* ») fidèle à sa data lake d'origine — c'est-à-dire dans lequel chaque valeur, pour chaque série et chaque date, correspond exactement à ce que contiennent les fichiers sources (bulletins institutionnels, CSV extraits de fichiers Excel remis par les institutions productrices, etc.). Cette étape a représenté une part importante du travail, car un modèle économétrique — aussi rigoureux soit-il — produit des résultats sans valeur si les données d'entrée sont mal alignées dans le temps.

2.1 Audit de fidélité

L'audit a été mené par **appariement valeur + date** plutôt que par confiance dans les métadonnées déjà inscrites dans le classeur (source, nom de fichier, etc.), ces dernières s'étant révélées, lors d'un contrôle préalable, insuffisamment fiables pour garantir l'alignement temporel des séries. La méthode retenue consiste, pour chaque colonne du classeur, à rechercher dans l'ensemble indexé de la data lake une série dont les couples (date, valeur) coïncident avec une tolérance quasi nulle.

- **Désalignement détecté et corrigé** : les colonnes d'indice de la production industrielle (IPI) présentaient un décalage d'environ 37 trimestres, provenant d'un collage séquentiel des données lors de la construction initiale du classeur, au lieu d'une jointure par date.
- **31 colonnes retirées** lors de l'audit initial car leur seule origine identifiable était un fichier consolidé (« BDD SECTORIEL ») sans lien retrouvé vers un fichier source primaire de la data lake, avec des valeurs à précision flottante inhabituelle (16-17 chiffres significatifs) faisant suspecter une origine calculée plutôt que recopiée.
- **30 de ces colonnes restaurées** ensuite, après confirmation par l'auteur du fichier consolidé des institutions productrices réelles (SIG Maroc, ACAPS, Bank Al-Maghrib, HCP, Index Mundi, OCP, ONEE, Office des Changes, ANRT selon la branche) — réintégrées avec un statut explicite « confirmé par l'auteur — date non vérifiée », plutôt que présentées comme pleinement vérifiées.
- **1 colonne (IPAI en niveau) reconstruite séparément** par chaînage des variations trimestrielles extraites directement des 72 bulletins PDF de l'ANCFCC/Bank Al-Maghrib disponibles dans le projet — 51 des 52 trimestres possibles (T3-2013 à T1-2026) ont pu être chaînés, seul le trimestre T2-2013 restant sans bulletin disponible.

2.2 Méthode d'appariement

Le script d'audit indexe l'ensemble de la data lake (hors le fichier consolidé lui-même, pour éviter qu'une colonne ne se confirme trivialement contre sa propre copie) puis, pour chaque colonne du classeur synthétique, calcule un score de correspondance :

- seuil de confirmation : au moins **85 %** des observations doivent trouver une correspondance exacte (tolérance 10^{-6} en valeur absolue, ou relative pour les grandes magnitudes) dans une série candidate de la data lake, à la même date ;
- gestion des deux conventions de date coexistant dans le classeur (label français abrégé, ex. « déc-07 », et clé normalisée, ex. « 2007M12 ») par un analyseur double format ;
- équivalence trimestre / fin de mois (« 2006T4 » ↔ « 2006M12 ») lorsque l'axe déclaré est trimestriel mais que la source de la data lake est indexée par fin de mois.

2.3 Traitement des colonnes non vérifiables

Vingt colonnes supplémentaires (hors IPAI) provenaient exclusivement du fichier consolidé « BDD SECTORIEL.xlsx », introuvable ailleurs dans la data lake malgré une recherche exhaustive (texte brut et appariement valeur/date sur 481 fichiers, 2071 séries indexées). L'inspection du fichier original (retrouvé via une sauvegarde de messagerie, propriétés du classeur : auteur Alim ATCHADAM, créé le 22/07/2026) n'a révélé aucune métadonnée supplémentaire — ni commentaire de cellule, ni formule. Face à cette absence de source primaire vérifiable, la décision a été prise, en accord avec le commanditaire du stage, de réintégrer ces séries en leur attribuant un statut de confiance explicite plutôt que de les exclure ou de les faire passer pour pleinement vérifiées.

Principe retenu pour la classification de fiabilité

Chaque colonne du classeur final porte un statut parmi quatre : **vérifiée** (valeur et date confirmées par appariement direct dans la data lake, 1157 colonnes) ; **vérifiée — réalignée** (correction de date appliquée lors de l'audit, 47 colonnes) ; **confirmée par l'auteur — non vérifiable** (source institutionnelle confirmée mais alignement des dates non prouvable faute de fichier primaire, 30 colonnes) ; **reconstruite** (recalculée par chaînage à partir de composantes elles-mêmes vérifiées, 1 colonne — l'indice IPAI). Un code couleur cohérent (blanc / bleu / orange / gris) matérialise ce statut directement sur chaque feuille de données et dans une légende dédiée.

2.4 Traçabilité et vérification finale

Chaque restauration a fait l'objet d'une vérification exhaustive cellule par cellule contre l'état du classeur juste avant son retrait (extrait de l'historique Git, antérieur à toute correction de cette phase de travail) :

Opération	Résultat de vérification
Remplacement de 2 séries mal alignées	8 062 cellules vérifiées, 0 écart
Restauration des 10 premières colonnes confirmées	902 valeurs identiques, 0 différence, 0 manquant
Restauration des 20 colonnes restantes	1 728 valeurs identiques, 0 différence, 0 manquant
Reconstruction IPAI (chaînage bulletins)	51/52 trimestres chaînés, T3-2013 → T1-2026

Le classeur final compte **1 235 colonnes** réparties sur 17 branches d'activité (complétées par 4 branches manquantes de la comptabilité nationale ajoutées en cours de route : Administration publique, Éducation-santé, Services aux entreprises, Autres services), avec une feuille Métadonnées documentant institution productrice, fichier source, période couverte et statut de fiabilité pour chaque série.

Partie II — Modélisation économétrique

Le modèle GDPNow-Maroc adapte l'architecture de Higgins (2014) à une logique **offre** (production par branche d'activité, nomenclature proche du HCP) plutôt que **demande** (consommation, investissement, dépenses publiques, commerce extérieur, comme dans le GDPNow original). Seize branches sont modélisées ; sept disposent d'au moins un indicateur infra-annuel validé, les neuf autres sont traitées par une prévision autorégressive pure, faute de série mensuelle ou trimestrielle disponible avec une corrélation suffisante.

3. Étape préalable — stationnarisation

Un test de racine unitaire de Dickey-Fuller augmenté est appliqué à chaque série de valeur ajoutée, en niveau puis en taux de croissance logarithmique :

$$\Delta y_t = \alpha + \rho y_{t-1} + \sum_{k=1}^4 \gamma_k \Delta y_{t-k} + \varepsilon_t \quad H_0 : \rho = 0$$

Test ADF : H_0 = présence d'une racine unitaire (non-stationnarité), retenu avec 4 retards.

$$\Delta \log(VA_{b,t}) = \log(VA_{b,t}) - \log(VA_{b,t-1})$$

Transformation en taux de croissance trimestriel ($\Delta \log$), appliquée à chaque branche b .

Résultat empirique : **1 branche sur 16 seulement est stationnaire en niveau, contre 16 sur 16 en $\Delta \log$** . Ce résultat, cohérent avec la pratique de Higgins (2014) — dont toutes les équations du modèle GDPNow sont écrites en variation logarithmique — justifie de modéliser des taux de croissance dans l'ensemble du pipeline plutôt que des niveaux.

4. Bloc 1 — BVAR trimestriel à prior Minnesota

Les 16 taux de croissance sont modélisés conjointement par un vecteur autorégressif bayésien (BVAR) à 5 retards, estimé par la méthode des observations fictives de Litterman (1986), reprise et généralisée à un grand nombre de variables par Bańbura, Giannone & Reichlin (2010) — la même approche que celle documentée en annexe du papier GDPNow original.

$$Y_t = c + \sum_{l=1}^p B_l Y_{t-l} + u_t, \quad u_t \sim \mathcal{N}(0, \Sigma)$$

Forme VAR(p) de base : Y_t vecteur des 16 $\Delta \log$ de valeur ajoutée, $p = 5$ retards.

Le prior impose une contraction des coefficients vers une valeur cible δ_i , avec une variance décroissante à mesure que le retard s'éloigne et que l'échelle des variables diffère :

$$E[(B_l)_{ii}] = \delta_i \quad (l = 1), \quad E[(B_l)_{ij}] = 0 \quad (i \neq j)$$

Puisque les variables sont déjà des taux de croissance (non des log-niveaux), $\delta_i = 0$ pour toutes les branches — prior de retour à la moyenne, non de marche aléatoire.

$$\text{Var}[(B_l)_{ij}] = \frac{\lambda^2}{l^2} \cdot \frac{\sigma_i^2}{\sigma_j^2}$$

λ contrôle le degré de resserrement global du prior ($\lambda = 0,15$, valeur retenue par Higgins pour son BVAR trimestriel de composantes de quantité — nature de variable comparable).

En pratique, ce prior est implémenté sous forme d'« observations fictives » — des lignes supplémentaires ajoutées à la régression, dont l'effet équivaut à une estimation bayésienne :

$$X_d^{(1)}[l] = \text{diag}\left(\frac{l \cdot \sigma_1}{\lambda}, \dots, \frac{l \cdot \sigma_n}{\lambda}\right), \quad l = 1, \dots, p$$

Bloc d'observations fictives imposant le prior sur les coefficients autorégressifs.

$$\hat{B} = (X_{\text{aug}}^\top X_{\text{aug}})^{-1} X_{\text{aug}}^\top Y_{\text{aug}}, \quad X_{\text{aug}} = [X; X_d], \quad Y_{\text{aug}} = [Y; Y_d]$$

Estimateur final : moindres carrés sur les données réelles augmentées des observations fictives — équivalent à une régression ridge bayésienne.

5. Bloc 2 — équations de passerelle (« bridge equations »)

Pour les sept branches disposant d'au moins un indicateur infra-annuel retenu (après un processus de sélection à 8 critères — fréquence, longueur, fraîcheur, densité, corrélation à la cible, cohérence du signe, non-redondance, unicité de la cible par branche, inspiré du critère de corrélation de Fernández Cerezo, 2023), une régression simple relie la croissance de la valeur ajoutée à celle de chaque indicateur :

$$\Delta \log(VA_{b,t}) = \varphi_b + \theta_b \Delta \log(x_{b,t}) + \varepsilon_t$$

Équation de passerelle individuelle (Higgins 2014, éq. 6) — x = indicateur retenu.

Lorsqu'une branche dispose de plusieurs indicateurs, les prévisions individuelles sont moyennées à parts égales — une approximation documentée de l'équation 7 du papier original, faute de disposer des poids de valeur ajoutée nominale par sous-branche que Higgins utilise pour pondérer ses propres bridge equations :

$$\widehat{\Delta \log(VA_b)}^{\text{bridge}} = \frac{1}{n_b} \sum_{k=1}^{n_b} \widehat{\Delta \log(VA_b)}^{(k)}$$

Moyenne simple des n_b prévisions individuelles disponibles pour la branche b .

La prévision « bridge » est enfin combinée à la prévision issue du BVAR (bloc 1) par moindres carrés restreints, en optimisant un poids δ_b compris entre 0 et 1 (Higgins 2014, éq. 8) :

$$\begin{aligned} \widehat{\Delta \log(VA_b)} &= \delta_b \widehat{\Delta \log(VA_b)}^{\text{BVAR}} + (1 - \delta_b) \widehat{\Delta \log(VA_b)}^{\text{bridge}} \\ \delta_b^* &= \arg \min_{\delta \in [0,1]} \sum_t (\Delta \log(VA_{b,t}) - \delta \hat{y}_t^{\text{BVAR}} - (1 - \delta) \hat{y}_t^{\text{bridge}})^2 \end{aligned}$$

δ_b optimisé en minimisant l'erreur quadratique en échantillon — plus l'équation de passerelle explique bien la cible, plus son poids $(1 - \delta_b)$ est élevé.

6. Bloc 3 — branches non couvertes (AR(4))

Les neuf branches sans indicateur infra-annuel validé reçoivent une prévision purement autorégressive — le traitement que Higgins (2014) applique lui-même, dans le modèle GDPNow original, à toute sous-composante ne disposant d'aucune série mensuelle exploitable (dortoirs dans l'investissement résidentiel, par exemple) :

$$\Delta \log(VA_{b,t}) = c_b + \sum_{k=1}^4 \phi_{b,k} \Delta \log(VA_{b,t-k}) + \varepsilon_t$$

7. Agrégation en nowcast du PIB

Les 16 prévisions de branche sont combinées en une prévision de croissance du PIB total, pondérées par la part de chaque branche dans la valeur ajoutée totale (en volume, dernier trimestre observé) :

$$w_{b,T} = \frac{VA_{b,T}}{\sum_{j=1}^{16} VA_{j,T}}$$

$$\Delta \log(PIB_{T+1}) \approx \sum_{b=1}^{16} w_{b,T} \cdot \widehat{\Delta \log(VA_{b,T+1})}$$

Approximation log-linéaire de premier ordre de l'agrégation Fisher/Törnqvist (Whelan, 2000) — les vrais poids de Fisher demanderaient les valeurs à prix courants pour les 16 branches, non disponibles à ce stade (limite documentée en section 9). Pour mémoire, la formule exacte de chaînage Fisher utilisée par le PIB officiel (et par le GDPNow original) est :

$$REALGDP\% \Delta_t = \sqrt{\frac{\sum_i Q_t^i P_{t-1}^i}{\sum_i Q_{t-1}^i P_{t-1}^i} \cdot \frac{\sum_i Q_t^i P_t^i}{\sum_i Q_{t-1}^i P_t^i}} - 1$$

Chaînage Fisher exact (Higgins 2014, annexe, éq. A3) — Q = quantité, P = prix, i = composante. Non implémenté ici faute de données de prix par branche.

8. Traitement des données manquantes

Aucune méthode d'imputation n'est utilisée à quelque étape que ce soit du pipeline : le traitement retenu est la **suppression de cas incomplets** (listwise deletion), à trois niveaux distincts.

- **À l'import** : toute ligne dont la date ou la valeur est absente est simplement filtrée, sans être comblée.
- **À l'agrégation mensuel → trimestriel** : un indicateur mensuel est ramené au trimestre par moyenne des mois disponibles (moyenne partielle si un mois manque, sans pondération particulière ni signalement du trimestre incomplet).
- **Dans le BVAR** : seuls les trimestres où les 16 branches disposent toutes d'une valeur simultanément sont conservés — un filtre strict (« cas complet ») appliqué à l'ensemble du panel avant estimation.

Une vérification empirique a montré que ce filtre n'a, dans les faits, retiré aucune observation : les 16 séries cibles forment un panel parfaitement équilibré, 113 trimestres identiques de 1998T1 à 2026T1 pour chacune des 16 branches (la matrice finale utilisée par le BVAR compte 112 observations, la perte d'une unité provenant uniquement de la différenciation logarithmique, non d'un trou de données).

Limite méthodologique à retenir

Le comportement du filtre en présence d'un vrai déséquilibre entre branches (par exemple, une branche dont la dernière valeur n'est pas encore publiée alors que les 15 autres le sont) n'a jamais été testé sur les données historiques disponibles, puisque le panel s'est avéré déjà complet. C'est pourtant précisément le cas d'usage du nowcasting en production : traiter des données arrivant à des rythmes différents (« jagged edge », Giannone, Reichlin & Small, 2008). Le vrai GDPNow gère ce problème par un filtre de Kalman et un algorithme Espérance-Maximisation qui estiment les valeurs manquantes de façon probabiliste ; rien d'équivalent n'est implémenté ici. Le risque est concentré non pas sur les 16 cibles (actuellement équilibrées) mais sur les 41 indicateurs infra-annuels, chacun avec son propre historique et ses propres trous, gérés au cas par cas dans chaque régression individuelle.

9. Résultats obtenus

Exécuté sur les données disponibles à la date de rédaction (dernière valeur ajoutée officielle connue : T1-2026 ; derniers indicateurs disponibles : mai 2026), le pipeline produit un nowcast pour le trimestre suivant la dernière valeur ajoutée publiée — soit T2-2026, le trimestre dont le PIB n'est pas encore publié mais pour lequel des indicateurs infra-annuels sont déjà partiellement disponibles.

Indicateur	Valeur
Nowcast de croissance du PIB ($\Delta\log$, T2-2026)	+0,86 %
Branches stationnaires en $\Delta\log$	16 / 16
Branches couvertes par un indicateur infra-annuel	7 / 16
Branches en AR(4) pur	9 / 16
RMSFE du modèle complet (backtest, 8 trimestres)	0,0074
RMSFE du repère AR(2) sur PIB total	0,0067
Test de Diebold-Mariano (modèle vs. AR(2))	p = 0,236 (non significatif)

Le test de Diebold-Mariano compare, trimestre par trimestre, l'écart au carré entre la prévision et la valeur réalisée pour deux modèles (le modèle complet et un simple AR(2) sur le PIB agrégé), et teste si la moyenne de cet écart est statistiquement différente de zéro :

$$d_h = e_{1,h}^2 - e_{2,h}^2, \quad DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \sim \mathcal{N}(0, 1)$$

d_h = différence des erreurs quadratiques au trimestre h ; DM suit asymptotiquement une loi normale centrée réduite sous H_0 (précision identique).

$$\text{RMSFE} = \sqrt{\frac{1}{H} \sum_{h=1}^H (\Delta\log(\text{PIB})_h - \widehat{\Delta\log(\text{PIB})}_h)^2}$$

Racine de l'erreur quadratique moyenne de prévision, calculée sur $H = 8$ trimestres de backtest en pseudo temps réel (ré-estimation complète à chaque origine).

10. Limites méthodologiques assumées

- **Le modèle ne bat pas le repère naïf** sur la fenêtre de backtest testée, et l'écart n'est pas statistiquement significatif — l'échantillon de 8 trimestres est de toute façon trop court pour trancher dans un sens ou dans l'autre.
- **Le poids δ_b (bridge vs. BVAR) est optimisé en échantillon**, sur les mêmes données qui servent ensuite à évaluer le modèle — biais optimiste classique, la performance réelle en temps réel est probablement inférieure à celle mesurée.
- **Poids d'agrégation approximatifs** : parts de valeur ajoutée en volume (prix chaînés), non strictement additives — la vraie pondération Fisher/Törnqvist demanderait les valeurs à prix courants, non disponibles pour les 16 branches à ce stade.
- **Absence de poids de sous-branche** pour la moyenne des prévisions bridge (équation 7 de Higgins 2014 non reproduite, faute de données de valeur ajoutée nominale par sous-branche).
- **9 branches sur 16 sans indicateur infra-annuel réel** — traitées en AR(4) pur, c'est-à-dire extrapolées sans aucune information nouvelle sur le trimestre visé.
- **7 des 41 indicateurs retenus ont un signe de corrélation contre-intuitif**, inclus tels quels dans les bridge equations, sans traitement particulier.
- **Choc Covid-19 (2020)** visible sur la quasi-totalité des séries, non isolé par une variable indicatrice de rupture structurelle dans le BVAR — peut fausser l'estimation du prior et des écarts-types.
- **Traitement des données manquantes non testé** en conditions réelles de déséquilibre entre branches (cf. section 8) — risque concentré sur les indicateurs plutôt que sur les cibles.
- **30 des 1 235 colonnes du classeur source** portent un statut « confirmé par l'auteur — date non vérifiée » : la fiabilité du nowcast pour les branches concernées hérite de cette incertitude en amont.

11. Évaluation globale de la fiabilité

Le pipeline constitue un **prototype méthodologiquement défendable**, avec une architecture correctement ancrée dans la littérature de référence et des limites documentées avec transparence plutôt que dissimulées. Il ne constitue pas, en l'état, un **modèle opérationnel fiable** : sa valeur ajoutée par rapport à un simple modèle autorégressif sur le PIB agrégé reste à démontrer sur un échantillon de validation plus long, et plusieurs choix d'approximation (pondération d'agrégation, absence de poids de sous-branche, optimisation du δ en échantillon) devront être révisés avant tout usage en production.

12. Conclusion et pistes d'amélioration

- Étendre la fenêtre de backtest dès que l'historique de données le permet, pour donner une puissance statistique réelle au test de Diebold-Mariano.
- Sortir l'estimation du poids δ_b de la logique in-sample (validation croisée temporelle ou fenêtre glissante) pour obtenir une mesure de performance non biaisée.
- Investiguer les 7 indicateurs à signe de corrélation contre-intuitif avant de les conserver tels quels dans les bridge equations.
- Introduire une variable indicatrice (ou un traitement robuste) pour le choc Covid-19 dans l'estimation du BVAR.

- Obtenir les valeurs de valeur ajoutée à prix courants par branche (et par sous-branche, pour les 7 branches couvertes) afin de mettre en œuvre la pondération Fisher/Törnqvist complète, conforme à l'équation A3 du modèle GDPNow original.
- Remplacer le filtrage listwise strict par une méthode adaptée aux données décalées (filtre de Kalman, EM) avant tout déploiement en conditions réelles de nowcasting.

Références bibliographiques

- Bańbura, M., Giannone, D. & Reichlin, L. (2010). Large Bayesian VARs. *Journal of Applied Econometrics*, 25(1), 71-92.
- Diebold, F.X. & Mariano, R.S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3).
- Fernández Cerezo, A. (2023). A Supply-Side GDP Nowcasting Model. *Banco de España, Economic Bulletin*.
- Giannone, D., Reichlin, L. & Small, D. (2008). Nowcasting: The Real-Time Informational Content of Macroeconomic Data. *Journal of Monetary Economics*, 55, 665-676.
- Higgins, P. (2014). GDPNow: A Model for GDP “Nowcasting”. *Federal Reserve Bank of Atlanta, Working Paper* 2014-7.
- Litterman, R. (1986). Forecasting with Bayesian Vector Autoregressions — Five Years of Experience. *Journal of Business & Economic Statistics*, 4(1).
- Miller, P.J. & Chin, D.M. (1996). Using Monthly Data to Improve Quarterly Model Forecasts. *Federal Reserve Bank of Minneapolis Quarterly Review*, 20(2), 16-33.
- Stock, J.H. & Watson, M.W. (2007). Why Has U.S. Inflation Become Harder to Forecast? *Journal of Money, Credit and Banking*, 39(1), 3-33.
- Whelan, K. (2000). A Guide to the Use of Chain Aggregated NIPA Data. *Federal Reserve Board, FEDS Working Paper* 2000-35.